

Санкт-Петербургский Политехнический Университет Петра Великого  
Институт компьютерных наук и технологий  
Кафедра компьютерных систем и программных технологий

**РЕФЕРАТ**

**Тема:** Перспективные подходы в области распознавания образов с  
минимальной априорной информацией

**Дисциплина:** Интеллектуальные системы

Выполнил студент гр. 13541/3

\_\_\_\_\_ Д.В. Круминьш  
(подпись)

Руководитель

\_\_\_\_\_ Е.Н. Бендерская  
(подпись)

”\_\_” \_\_\_\_\_ 2017 г.

Санкт-Петербург  
2017

# Содержание

<b>1</b>	<b>Введение</b>	<b>2</b>
<b>2</b>	<b>Распознавание образов</b>	<b>3</b>
2.1	Задачи классификации . . . . .	3
<b>3</b>	<b>Априорная информация</b>	<b>6</b>
<b>4</b>	<b>Виды нейронных сетей</b>	<b>8</b>
4.1	Рекуррентные нейронные сети . . . . .	8
4.2	Сверточные нейронные сети . . . . .	10
4.3	Хаотические нейронные сети . . . . .	11
4.4	Осцилляторные нейронные сети . . . . .	12
4.5	Глубокие нейронные сети . . . . .	13
<b>5</b>	<b>Применение</b>	<b>15</b>
5.1	Tesla . . . . .	15
5.2	Google . . . . .	16
5.3	Apple . . . . .	16
5.4	Ударные мини дроны . . . . .	17
<b>6</b>	<b>Вывод</b>	<b>18</b>
	Список литературы . . . . .	19

# Введение

Современный мир развивается стремительными темпами, что влечёт за собой генерацию и накопление огромного количества данных, которые могут содержать в себе полезную практическую и теоретическую информацию. Как правило подобные данные, полученные из разнообразных источников, имеют неструктурированный характер и их необходимо обрабатывать, распознавая на них определенные образы.

Сфера распознавания образов существует уже достаточно долгое время, и уже успела себя зарекомендовать во многих областях. Но технологический процесс не стоит на месте, миниатюризация и увеличение быстродействия вычислительных машин открывают возможности к использованию более сложных алгоритмов или ускорению существующих, что означает расширение границ применимости распознавания образов.

Априорная информация в данном контексте выступает предварительно известной информацией о возможных классах объектов при распознавании, а также возможных решениях.

В данной работе рассматриваются:

1. Что такое распознавание образов;
2. Априорная информация;
3. Применяемые нейронные сети;
4. Существующие примеры использования.

# Распознавание образов

Распознавание образов это процесс формальной классификации (категорирования). Данный процесс не сводится лишь к обнаружению объекта, необходимо произвести оценку и анализ полученных данных. Компьютеры не «видят» фотографии и видео так же, как люди.

Когда человек смотрит на фотографию, он может увидеть своего лучшего друга, стоящего перед домом. С точки зрения компьютера, это же изображение представляет собой просто набор данных, которые он может интерпретировать как формы и информацию о значениях цвета. Хотя компьютер не будет реагировать так, как человек, видя эту фотографию, компьютер может быть обучен распознавать определенные шаблоны цвета и формы. Например, компьютер может быть обучен распознавать общие шаблоны форм и цветов, которые составляют цифровой образ лица, дома, или чего либо ещё.

Важное место в теории распознавания образов занимает классификация – некое решающее правило, относящее образ к одному из известных классов на основании предъявленного вектора признаков.

## 2.1 Задачи классификации

Классификация сложных объектов или явлений требует создания специальных систем распознавания – сложных динамических систем, состоящих в общем случае:

- совокупности технических средств получения и обработки информации;
- алгоритмов задач распознавания;
- априорной информации об объектах.

В процессе проектирования и построения классификаторов возникают задачи:

- Определение признаков объектов.
  - Заключается в том, чтобы определить полный набор признаков, характеризующих объекты или явления, для распознавания которых разрабатывается данная система. Названная совокупность признаков должна быть сформирована без относительно каких-либо ограничений, связанных как с получением априорной информации, необходимой для исходного описания классов объектов, так и с получением апостериорной информации о конкретных объектах, подлежащих распознаванию. Наоборот, первоначально необходимо определить все признаки, хотя бы в малейшей мере характеризующие объекты или явления.
- Составление априорного алфавита классов.
  - Заключается в проведении первоначальной классификации распознаваемых объектов или явлений и в составлении априорного алфавита классов. Главным в этой задаче является выбор правильного принципа классификации, удовлетворяющего требованиям, предъявляемым к системе классификации, которые в свою очередь зависят от того, какие решения могут приниматься системой управления по результатам распознавания неизвестных объектов или явлений. При решении последующих задач из априорного алфавита классов формируется рабочий алфавит классов системы.
- Разработка априорного словаря признаков.
  - Заключается в разработке априорного словаря признаков, в который войдут только те признаки, относительно которых может быть получена априорная информация, необходимая для описания классов на языке этих признаков.
- Описание классов объектов на языке признаков.
  - Состоит в описании всех классов априорного алфавита классов на языке признаков, включенных в априорный словарь признаков. Данная задача может быть решена с помощью методов обучения, самообучения или непосредственной обработки исходных данных.

- Разбиение априорного пространства признаков на области, соответствующие классам априорного алфавита классов.
  - Должна быть решена оптимальным, насколько это возможно, способом, например, чтобы обеспечить минимальное значение ошибок, неизбежно сопровождающих распознавание поступающих на вход системы распознавания объектов или явлений. Если разбиение объектов на классы  $K_1, K_2, \dots, K_m$  произведено, требуется выделить в пространстве признаков области  $D_i, i = 1, \vec{m}$ , эквивалентные классам. Это означает, что если объект, имеющий признаки  $x_1, x_2, \dots, x_N$ , относится к классу  $K_i$ , то представляющая его точка в пространстве признаков принадлежит области  $D_i$ .
- Построение рабочего алфавита признаков и классов.
  - Разработка такого алфавита классов и такого словаря признаков, которые в условиях ограничений на построение системы распознавания обеспечивают максимальное значение показателя эффективности системы распознавания, принимающей в зависимости от результатов распознавания неизвестных объектов соответствующие решения.
- Оценка эффективности работы системы.
  - Выбор показателей эффективности системы распознавания и оценке их значений. В качестве показателей эффективности системы могут быть выбраны, например, среднее время распознавания, вероятность правильной работы, величина расходов, связанных с получением апостериорной информации и т.д.

# Априорная информация

Системы по распознаванию образов, в зависимости от априорной информации можно разделить на следующие типы:

1. Системы без обучения;
2. Системы с обучением;
3. Самообучающиеся системы.

Рассмотрим системы без обучения, в таких системах, как правило, априорной информации достаточно для того, чтобы определить априорный алфавит классов, построить априорный словарь признаков и на основе непосредственной обработки исходных данных произвести описание каждого класса на языке этих признаков.

Априорная информация включает в себя:

- сведения о природе распознаваемых объектов или явлений;
- решения, которые могут приниматься на основе результатов распознавания;
- данные для построения априорного словаря признаков;
- зависимости между классами и признаками априорного словаря.

Первые два пункта являются исходными для определения принципа классификации и собственно проведения классификации.

Построение систем с обучением необходимо в том случае, когда отсутствует полная первоначальная априорная информация. Ее объем позволяет подразделить объекты на классы и определить априорный словарь признаков. Однако объем априорной информации недостаточен для того, чтобы в признаковом пространстве путем непосредственной обработки исходных данных построить описания классов объектов  $K_1, K_2, \dots, K_m$  на языке априорного словаря признаков. Такими

описаниями могут быть, например, разделяющие функции  $F_i(x_1, x_2, \dots, x_n)$ ,  $i = 1, m$ .

Изначально все множество объектов подразделено на классы  $K_1, K_2, \dots, K_m$  и определен вектор  $X = x_1, x_2, \dots, x_n$ , компоненты которого и составляют априорный словарь признаков.

Требуется на основании предъявления системе распознавания объектов обучающей выборки с указанием классов, которым они принадлежат, построить в многомерном признаковом пространстве гиперповерхность, разделяющую это пространство на области  $D_i$ , соответствующие классам  $K_i$ ,  $i = 1, m$ . При этом разделение должно осуществляться в соответствии с заранее выбранным критерием оптимизации.

Если обучающая выборка достаточно представительна, то, в пределе подобная процедура приводит к достаточно точному описанию классов и, следовательно, возможности определения таких границ классов, придерживаясь которых можно достичь потенциально достижимой точности работы системы распознавания.



# Виды нейронных сетей

В данном разделе выделены типы нейронных сетей, представляющие особый интерес для применения в области распознавания образов с точки зрения возможности проведения динамического анализа и эффективности получаемых результатов

## 4.1 Рекуррентные нейронные сети

Рекуррентными называются нейронные сети, имеющие одну или несколько обратных связей (рис. 4.1). Обратные связи могут быть локального и глобального типов. Рекуррентные сети, как правило, используются в качестве ассоциативной памяти или сети отображения вход-выход. Применение обратной связи позволяет нейронным сетям представлять состояния, что делает их удобным инструментом в различных приложениях обработки сигнала и управления [4].

В класс рекуррентных сетей с глобальной связью входят следующие основные архитектуры сетей:

1. сети нелинейной авторегрессии с внешними входами, в них используется обратная связь между выходными и входными слоями;
2. полносвязные рекуррентные сети с обратной связью между скрытым и входным слоем;
3. рекуррентный многослойный перцептрон, содержащий более одного скрытого слоя, с обратными связями между каждым из расчетных слоев и входным слоем;
4. рекуррентные сети второго порядка, использующие нейроны второго порядка.




Рис. 4.1: Пример рекуррентной сети

Первые три типа рекуррентных сетей допускают использование пространства состояний для изучения динамики среды. Этот подход берет начало в современной теории управления и является мощным методом изучения нелинейной динамики рекуррентных сетей.

Для обучения рекуррентных сетей можно выделить несколько различных по своей сути групп подходов [5]:

1. использование известных соотношений между параметрами рекуррентной нейронной сети и ее динамикой (например, нейронная сеть Хакена и другие аттракторные рекуррентные нейронные сети, в которых путем задания весовых коэффициентов можно закодировать желаемые аттракторы на базе правила Хэбба);
2. использование алгоритмов обучения с учителем на базе методов оптимизации по типу алгоритма обратного распространения ошибки (например, алгоритмы обратного распространения во времени, рекуррентное обучение в реальном времени, рекуррентное обратное распространение и алгоритмы, использующие Калмановскую фильтрацию);

3. использование алгоритма обучения с учителем при рассмотрении сети как частично рекуррентной; сигналы с обратных связей рассматриваются как отдельные входные сигналы – контекстные нейроны, в результате задача обучения упрощается и сводится к обычным алгоритмам обучения нейронных сетей прямого распространения; к этому типу обучения относятся нейронные сети Элмана, Джордана и другие;
4. использование алгоритмов обучения без учителя (правило обучения Кохонена, синаптическая пластичность импульсных нейронных сетей);
5. отсутствие обучения в классическом смысле. Функции обучения возложены на специальное устройство – считыватель, который занимается классификацией динамики сети. такой принцип лег в основу новой парадигмы нейронных сетей резервуарные вычисления.

Основная идея резервуарных вычислений заключается в использовании рекуррентной нейронной сети как резервуара с богатой динамикой и мощными вычислительными возможностями. При этом резервуар формируется случайным образом, что исключает необходимость проводить его обучение. При подаче на вход резервуара непрерывного сигнала он попадает в определенный динамический режим или состояние. Это состояние зависит от входного сигнала. Резервуар формируется таким образом, чтобы для похожих входных сигналов это состояние было похожим, а для разных – разным.

## **4.2 Сверточные нейронные сети**

Сверточные нейронные сети обрабатывают исходное изображение не полностью, а отдельными «порциями», последовательно уменьшая его размер или выделяя характерные наиболее важные признаки, уходя на новый уровень абстракции. В этих сетях формируются так называемые карты признаков, которые стороннему наблюдателю кажутся размытыми, искаженными копиями исходного изображения, но для нейронной сети имеют совершенно иной смысл, содержат инварианты и характерные признаки. Основная идея сверточной нейронной сети заключается в чередовании субдискретизирующих (S-layers) слоев, сверточных (C-layers) слоев, а также полносвязных (F-layers) выходных слоев.




Рис. 4.2: Структура сверточной нейронной сети с тремя скрытыми слоями

Чередование слоев позволяет составлять карты признаков из карт предыдущего слоя, что способствует на практике распознаванию сложных иерархий признаков.

В сверточных слоях каждый фрагмент изображения поэлементно умножается на небольшую матрицу весов, результат подвергается операции суммирования. Полученная сумма определяет один пиксель выходного изображения, называемого картой признаков.

### 4.3 Хаотические нейронные сети

В хаотической динамике рождаются структуры под действием внешних возмущений, и она изначально может содержать все множество возможных вариантов. Хаотические системы позволяют выйти на следующий уровень обобщения и расширить возможности вычислений одновременно над целым множеством вариантов, причем это множество будет формироваться под воздействием внешних сигналов и тем самым обеспечивать приемлемую сложность. Во многом это похоже на парадигму, используемую в квантовых вычислениях, в этом случае до момента считывания ответа содержится все множество вариантов решений [6].

Хаотическая нейронная сеть представляет собой однослойную рекуррентную сеть, в которой элементы связаны каждый с каждым, без образования связи сам на себя:

$$y_i(t+1) = \frac{1}{C_i} \sum_{i \neq j}^N w_{ij} f(y_i(t)), t = 1, \dots, T \quad (4.1)$$

$$f(y(t)) = 1 - 2y^2(t), \quad (4.2)$$

$$w_{ij} = \exp\left(-\frac{|x_i - x_j|^2}{2a^2}\right) \quad (4.3)$$

где  $C_i = \sum_{i \neq j} w_{ij}$ ,  $i, j = \overline{1, N}$ ,  $a$  - масштабирующая константа,  $w_{ij}$  - сила связи (весовой коэффициент) между  $i$  и  $j$  нейронами,  $N$  — число нейронов соответствующее числу точек во входном образе, представленных в виде  $X = (x_1, x_2, \dots, x_m)$ ,  $m$  — размерность пространства образов,  $T$  — время моделирования.

Обучение хаотической нейронной сети заключается в назначении весовых коэффициентов сети, которые определяются исходя из входного образа по соотношению 4.3 и однозначно определяют поле, которое действует на все нейроны сети.

Примерами наиболее известных хаотических нейронных сетей могут служить модели обонятельной луковицы фримана (W.J. Freeman) [7] и хаотической нейронной сети айхары (K. Aihara) [8].

#### 4.4 Осцилляторные нейронные сети

Одним из перспективных средств, не использующих априорные знания об обрабатываемых данных, является осцилляторная нейронная сеть. Модель сети была разработана группой итальянских ученых под руководством Ангелини для задачи кластеризации в 2000 году [9].

Можно выделить следующие основные характеристики осцилляторной нейронной сети:

1. сеть является однослойной, рекуррентной и полносвязной;
2. элементами сети являются нейроны с передаточной функцией “логистическое отображение”;
3. сеть обладает свойством неаттракторности, то есть результат работы скрыт в динамике выходов нейронов;
4. для извлечения результата работы сети требуется анализ изменения выходов нейронов во времени.

Функциональной единицей сети, как правило, является осциллятор — множество совместно функционирующих элементов (нейронов или нейронных ансамблей), способных работать в колебательном режиме. В зависимости от целей исследования выбирается не только определенная архитектура связей сети, но и

конструкция отдельного осциллятора. В наиболее сложных и максимально приближенных к реальности моделях используются осцилляторы, состоящие из элементов с интегративно-пороговыми свойствами разной степени сложности, являющиеся аналогами биологических нейронов. Осциллятор включает нейроны как с тормозными, так и с возбуждающими связями. Это приводит к тому, что при определенных условиях суммарная активность нейронов приобретает колебательный характер [10].

Для примера рассмотрим модель фазового осциллятора Курамото, позволяющего исследовать процессы и режимы синхронизации между осцилляторами, которые зависят от структуры и параметров нейронной сети. Модель Курамото описывается следующим уравнением [11]:

$$\frac{\delta \theta_i}{\delta t} = w_i + \frac{K}{N} \sum_{j=1}^N \sin(\theta_j - \theta_i), i = 1, \dots, N \quad (4.4)$$

Фаза осциллятора  $\theta_i$  является основной переменной состояния и располагается в диапазоне от 0 до  $2\pi$ . Внутренняя частота осциллятора  $w_i$  в данной модели представляет собой смещение по фазе, проявляющееся в процессе синхронизации. Сила связи  $K$  между осцилляторами в нейронной сети является основным параметром, оказывающим влияние на режимы синхронизации. Параметр  $N$  в уравнении определяет количество осцилляторов в нейронной сети.

## 4.5 Глубокие нейронные сети

В 2006 году глубокое обучение было представлено в виде многослойной нейронной сети, первый слой которой выявлял основные особенности изображения, а последующие слои строили обобщенный образ объекта в виде комбинации простых примитивов. Процесс обучения осложнен наличием большого количества настраиваемых параметров. Обычно процесс обучения глубокой нейронной сети разбивают на два шага. На первом шаге проводится обучение однослойной сети, а на следующем шаге производится сопоставление весовых коэффициентов между слоями сети путем минимизации ошибки классификации. Такой подход позволяет сократить сложность обучения сети с большим количеством параметров благодаря оптимизации между слоями.

Глубокая нейронная сеть — это искусственная нейронная сеть с несколькими скрытыми слоями. Дополнительные слои позволяют строить абстракции все бо-

лее высоких уровней, что дает возможность формирования модели для распознавания сложных объектов реального мира. Обычно используются глубокие сети прямого распространения, однако, последние исследования показали успешное применение глубоких архитектур в рекуррентных сетях [12]. В задачах, связанных с обработкой изображений, преимущественно применяются сверточные нейронные сети ввиду их наибольшей эффективности.

Обучение глубоких нейронных сетей может быть осуществлено с помощью алгоритма обратного распространения ошибки. Таким образом, может быть использовано несколько правил настройки весов. Например, алгоритм стохастического градиентного спуска:

$$w_{ij}(t + 1) = w_{ij}(t) + \eta \frac{\delta L}{\delta w_{ij}} \quad (4.5)$$

где  $\eta$  — постоянная для регулирования величины текущего шага,  $L$  — функция потерь. Выбор функции потерь может быть обусловлен классом задачи машинного обучения (с учителем, без учителя, с подкреплением) и функции активации.

# Применение

Распознавание образов уже применяется повсюду, по большей части это коммерческая сфера деятельности.

## 5.1 Tesla

Компания Tesla делает первые шаги к созданию полностью беспилотного автомобиля. Благодаря быстрому распознаванию образов(разметки, пешеходов, других машин и т.д.), автопилот способен на:

1. **Автоматическое управление.** На скоростях свыше 20 км/ч Тесла сама разгоняется, тормозит и поворачивает, в чем ей помогает связка сенсоров и камер;
2. **Автоматическое перестроение.** В отличие от систем круиз-контроля, Тесла теперь умеет перестраиваться сама. Водителю достаточно лишь выбрать направление перестроения. При этом, в отличие от некоторых нерадивых водителей, машина сделает это безопасно, отслеживая все слепые зоны, и пдд;
3. **Автоматическая парковка.** Эта функция далеко не революционна, но в Tesla Motors утверждают, что их система у ближайшем будущем будет сама заезжать даже в гараж;
4. **Экстренное торможение.** Эту особенность тоже нельзя назвать совершенно новой, но тем не менее — Тесла умеет распознавать препятствие и экстренно гасить скорость вплоть до полной остановки в случае опасности;
5. **Самообучение.** Машина учитывает полосы движения, собирая данные при каждом включении автономной системы, затем отправляя их на сервера Tesla Motors. А потом полученные данные анализируются компанией, которая периодически выпускает обновления системы автопилота.



По заявлениям компании, полностью автономная машина будет продемонстрирована в конце 2017 года, и будет доступна для широкого использования к 2019 году.

## 5.2 Google

Компания Google является не только поисковиком, а чем-то гораздо большим. Во многих продуктах компании применяется распознавание образов, в частности:

### 1. Google карты

- Google одна из первых компаний, которая предоставляла в своих картах панорамный обзор. С их помощью можно не только увидеть чудеса природы и достопримечательности со всего света, но и изучить различные места в разных городах мира. Но тут возникает проблема конфиденциальности и огромного объема данных. Тут и приходит на помощь распознавание образов, для того чтобы сделать процесс наложения **blur** эффекта на лица людей и номера машин более автономным.

### 2. Google+ photos

- Благодаря технологии определения лиц, можно узнать на каких еще фотографиях присутствует необходимый человек.

### 3. Автопилот

- Google также как и Tesla работает над созданием беспилотного автомобиля, только в данном случае это пока проходит лишь в компании, не попадая на рынок к потребителю.

## 5.3 Apple

Не так давно компания Apple презентовала новую технологию **Face ID** - определения владельца устройства по лицу, учитывая то что он может надеть очки и головной убор. По заверениям компании данная технология работает весьма точно (вероятность ошибки 1 к 1 000 000).

Однако на презентации, технология не смогла успешно распознать своего владельца. Также технология крайне небезопасна, так как имея несколько фотогра-

фий владельца, можно сделать маску его лица, что позволит успешно пройти аутентификацию по лицу.

В целом данная технология весьма перспективна и требует дальнейших доработок по улучшению определения лица.

## **5.4 Ударные мини дроны**

Распознавание образов также не обходит и военную сферу. Чем-то новым на данный момент являются ударные мини дроны. Напечатанные на 3D-принтере аппараты можно запускать в сторону врага с истребителя или бомбардировщика. Дроны успешно распознают препятствия, в случае необходимости прокладывают себе путь, а также распознают противников и обезвреживают их.

## Вывод

Необходимость в распознавании образов в современном мире, с учетом его темпов роста, крайне велика. Объемы фото и видео информации, которые необходимо обработать уже давно вышли за пределы возможностей человека.

Распознавание образов строится на основе различных нейронных сетей. Одним из таких примеров являются хаотические нейронные сети, в которых рождаются структуры под действием внешних возмущений, то есть хаос здесь предстает как интерфейс между внешним миром и внутренней динамикой системы. Используя такие нейронные сети, конечная система обладает следующими свойствами:

- автономность (ослабление зависимости от априорной информации);
- адаптация (подстройка под решаемую задачу за счет динамики элементов системы, отличие новой информации от уже известной и обучение в реальном времени);
- комплексное восприятие образов (учет временного и пространственного контекста);
- адекватность сложности системы по сравнению со сложностью решаемой задачи.

Распознавание образов в мире уже давно широко используется, от распознавания лиц до полноценного беспилотного автомобиля. Точность распознавания образов из года в год только улучшается. В будущем распознавание образов будет лишь только расширять свой охват использования.

На мой взгляд, наибольшим потенциалом обладают сети с глубоким обучением. Например при увеличении количества слоев в сверточной нейронной сети, имеется возможность более точного определения. То есть каждый из слоев может

заниматься своей работой по распознаванию(искать свои признаки), и как итог соединять всю полученную информацию в одно целое, что означает повышение точности распознавания.

Также стоит отметить что необходимо распознавать и окружающую обстановку, так как это позволит отсеять сомнительные распознавания.

# Литература

- [1] Требования к созданию Сильного ИИ [Электронный ресурс]. — URL: <https://dic.academic.ru/dic.nsf/ruwiki/318696> (дата обращения: 2017-11-25).
- [2] Т.В. Арямова. Распознавание образов в управлении организацией. Синергетический аспект. — Известия ЮФУ. Технические науки., 1998. — URL: <http://cyberleninka.ru/article/n/raspoznavanie-obrazov-v-upravlenii-organizatsiey-sinergeticheskiy-aspekt> (дата обращения: 2017-11-25).
- [3] Методы самоорганизации [Электронный ресурс]. — URL: <http://www.smutc.ru/toxicity/ecological27.htm> (дата обращения: 2017-11-25).
- [4] С. Хайкин. Нейронные сети: полный курс, 2-е издание. — М.: Вильямс, 2008.
- [5] Е.Н. Бендерская, К.В. Никитин. Рекуррентная нейронная сеть как динамическая система и подходы к ее обучению. — Научно-технические ведомости Санкт-Петербургского государственного политехнического университета. Информатика. Телекоммуникации. Управление., 2013.
- [6] Е.Н. Бендерская, О.Н. Граничин. Использование сложности входного образа в управлении структурной сложностью интеллектуальной системы. — 5-я Российская мультikonференция по проблемам управления. Санкт-Петербург, 2012.
- [7] W. Freeman. Simulation of chaotic EEG patterns with a dynamic model of the olfactory system. — Biological Cybernetics., 1987.
- [8] K. Aihara, T. Takabe, M. Toyoda. Chaotic neural networks. — Physics Letters A., 1990.
- [9] Clustering Data by Inhomogeneous Chaotic Map Lattices / Angelini L., Carlo F., Marangi C. и др. — Physical Review Letters, 2000.

- [10] Осцилляторные нейронные сети. Математические результаты и приложения / Борисюк Г. Н., Борисюк Р. М., Казанович Я. Б. и др. — Математическое моделирование., 1992.
- [11] Е.Н. Бендерская, В. Новиков А. Применение процессов синхронизации в осцилляторных сетях для решения задач кластеризации. — СПИСОК- 2013: Материалы всероссийской научной конференции по проблемам информатики. Санкт-Петербург, 2013.
- [12] Recurrent neural network based language model / Mikolov T., Karafiat M., Burget L. и др. — 11th Annual Conference of the International Speech Communication Association. Japan., 2010.
- [13] Н.А. Лагунов. Применение сверточных нейронных сетей в задачах распознавания многопараметрических объектов. — Северо-Кавказский федеральный университет, 2013.